Der Faltplan

In 10 Schritten zur eigenen KI · selbst-gfaltet



1 ☐ **Grafikkarte prüfen**

Wie viel VRAM hast du? Im GPU-Rechner auf selbst-gfaltet nachschauen, welche Modelle passen.

2 ☐ **Ollama installieren**

Von ollama.com. Danach läuft es im Hintergrund.

3 ☐ **Erstes Modell laden**

ollama pull gemma4:e4b – das kleine Modell passt auf fast jede Karte.

4 ☐ **Ausprobieren und messen**

ollama run gemma4:e4b --verbose. Tokens pro Sekunde notieren.

5 ☐ **Größeres Modell testen**

Wenn genug Speicher da ist: ein größeres Modell laden und vergleichen.

6 ☐ **Eigene Oberfläche**

Kleiner Server (z. B. Node.js), der Nachrichten an Ollama weitergibt. Claude Code kann ihn für dich schreiben.

7 ☐ **Erste Werkzeuge**

Suchen, rechnen, Dateien lesen. Rechnen immer per Code, nie vom Modell.

8 ☐ **Freigaben einbauen**

Löschen, Installieren, Absenden nur nach deinem Okay. Im Code, nicht im Prompt.

9 ☐ **Login absichern**

Passwort plus Zwei-Faktor-Code, Sperre nach Fehlversuchen.

10 ☐ **Von unterwegs erreichbar**

Zum Beispiel über Tailscale, ohne den PC ins offene Internet zu stellen.

Alles abgehakt? Dann hast du dir deine eigene KI gefaltet. – Ori